Conceptos de Optimización para ML

I302 - Aprendizaje Automático y Aprendizaje Profundo

Clase Tutorial 1 - 1 Semestre 2025

Roberto Bunge - *rbunge@udesa.edu.ar*

Trinidad Monreal - *tmonreal@udesa.edu.ar*

Lucas Pancotto - *lpancotto@udesa.edu.ar*

Problema Genérico de Optimización

- Problema central en ML: estimación de parámetros (= ajuste del modelo)
- Esto requiere resolver un problema de **optimización**:

$$\underset{\mathbf{x}}{\text{minimize}} \quad f(\mathbf{x})$$
$$\text{subject to} \quad \mathbf{x} \in \mathcal{X}$$

- x: punto de diseño n-dimensional
  - $[x_1, x_2, ..., x_n]$
  - x_i: variable de diseño i-ésima
  - Los elementos del vector se ajustan para minimizar la **función objetivo** *f*.

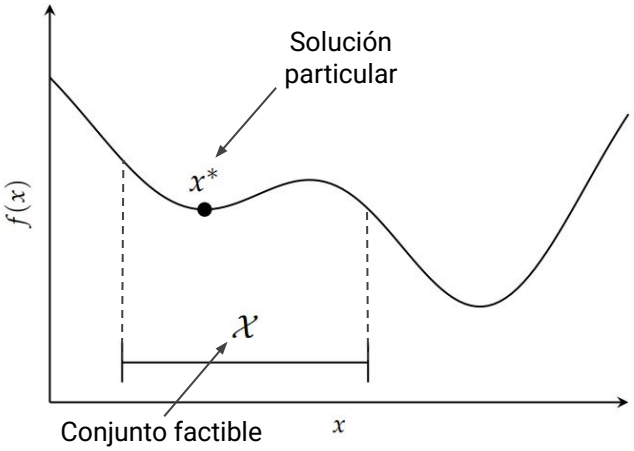

Restricciones

- Los problemas naturalmente tienen restricciones sobre los valores posibles
  - Un avión no puede tener alas de 0 m
  - La cantidad de horas semanales dedicadas a hacer un TP no puede superar 168 h
  - Administrador de fondos de cobertura no puede vender más acciones de las que tiene
- Incluimos restricciones en estos problemas para evitar que el algoritmo de optimización sugiera una solución inviable
- Cada restricción limita al conjunto de soluciones posibles
- Definen el conjunto factible $\mathcal{X} \leq R^n$
  - Si no hay restricción, $\mathcal{X} = R^n$

$$\begin{aligned} \underset{x_1, x_2}{\text{minimize}} \quad & f(x_1, x_2) \\ \text{subject to} \quad & x_1 \geq 0 \\ & x_2 \geq 0 \\ & x_1 + x_2 \leq 1 \end{aligned}$$

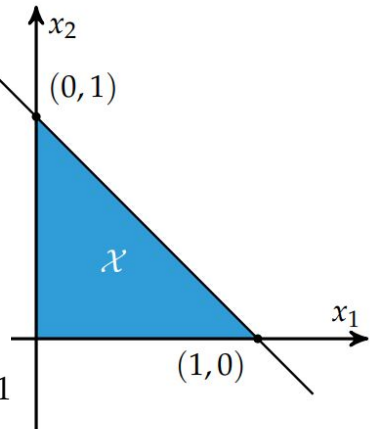

Restricciones

- Los conjuntos factibles suelen formarse por dos tipos de restricciones:
  - Restricciones de igualdad $h(\mathbf{x}) = 0$
  - Restricciones de desigualdad $g(\mathbf{x}) \leq 0$
- Podemos escribir cualquier problema de optimización como:

$$
\begin{aligned}
\underset{\mathbf{x}}{\text{minimize}} \quad & f(\mathbf{x}) \\
\text{subject to} \quad & h_i(\mathbf{x}) = 0 \ \text{ for all } \ i \text{ in } \{1, \ldots, \ell\} \\
& g_j(\mathbf{x}) \leq 0 \ \text{ for all } \ j \text{ in } \{1, \ldots, m\}
\end{aligned}
$$

Multiplicadores de Lagrange

- Los usamos para optimizar una función sujeta a restricciones de igualdad
- Es decir, tenemos:

$$\begin{aligned} \underset{\mathbf{x}}{\text{minimize}} \quad & f(\mathbf{x}) \\ \text{subject to} \quad & h(\mathbf{x}) = 0 \end{aligned}$$

  - La dirección de cambio de f (∇f) es perpendicular a sus líneas de contorno

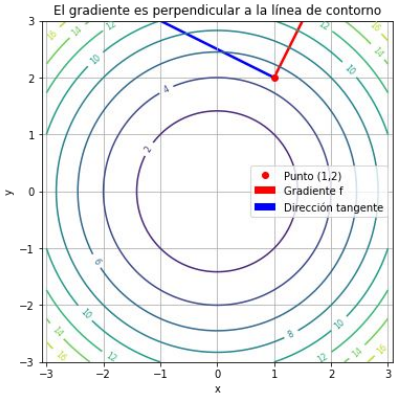

Conjuntos de puntos en el plano (x_1,x_2) para los cuales la función f toma un valor constante

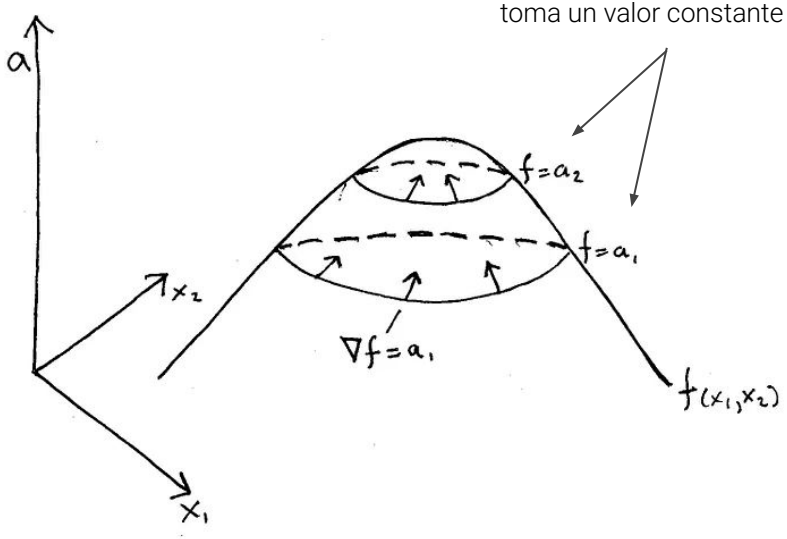

Multiplicadores de Lagrange

- Los usamos para optimizar una función sujeta a restricciones de igualdad
- Es decir, tenemos:

$$\begin{aligned} \underset{\mathbf{x}}{\text{minimize}} \quad & f(\mathbf{x}) \\ \text{subject to} \quad & h(\mathbf{x}) = 0 \end{aligned}$$

  - La dirección de cambio de f (∇f) es perpendicular a sus líneas de contorno
  - La restricción h(x) = 0 define una curva/ superficie
  - En el óptimo, ∇f y ∇h deben apuntar en la misma dirección: $\nabla f(\mathbf{x}) = \lambda \nabla h(\mathbf{x})$

Puede que las magnitudes no sean iguales

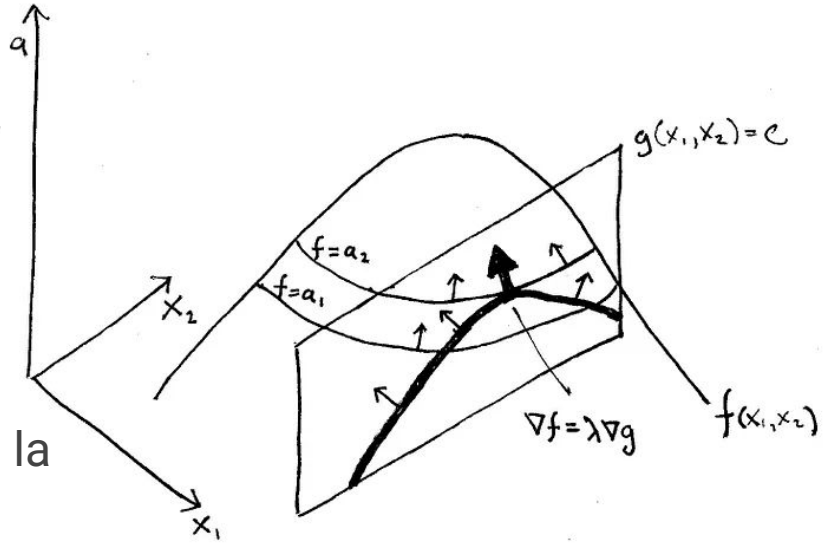

Multiplicadores de Lagrange

- Definimos la función Lagrangiana: $\boxed{\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) - \lambda h(\mathbf{x})}$
  - Resolver $\nabla \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{0}$ resuelve:
    - $\nabla_{\mathbf{x}} \mathcal{L} = \mathbf{0} \longrightarrow \nabla f(\mathbf{x}) = \lambda \nabla h(\mathbf{x})$
    - $\nabla_{\lambda} \mathcal{L} = 0 \longrightarrow h(\mathbf{x}) = 0$ (restricción original)
- Esto nos da el punto donde se optimiza $f(x)$ cumpliendo la restricción
- Convertimos un problema restringido a uno no restringido
- Cualquier solución se considera un *punto crítico* (mín local, mín global o punto silla)

Puntos Críticos

- **Óptimo global:** Punto x dentro del conjunto factible que alcanza el valor óptimo
- **Óptimo local:** Punto x que es óptimo un vecindario infinitesimal alrededor suyo

$$\boxed{\min \quad (1/5)x^6 - (5/4)x^4 + 2x^2}$$

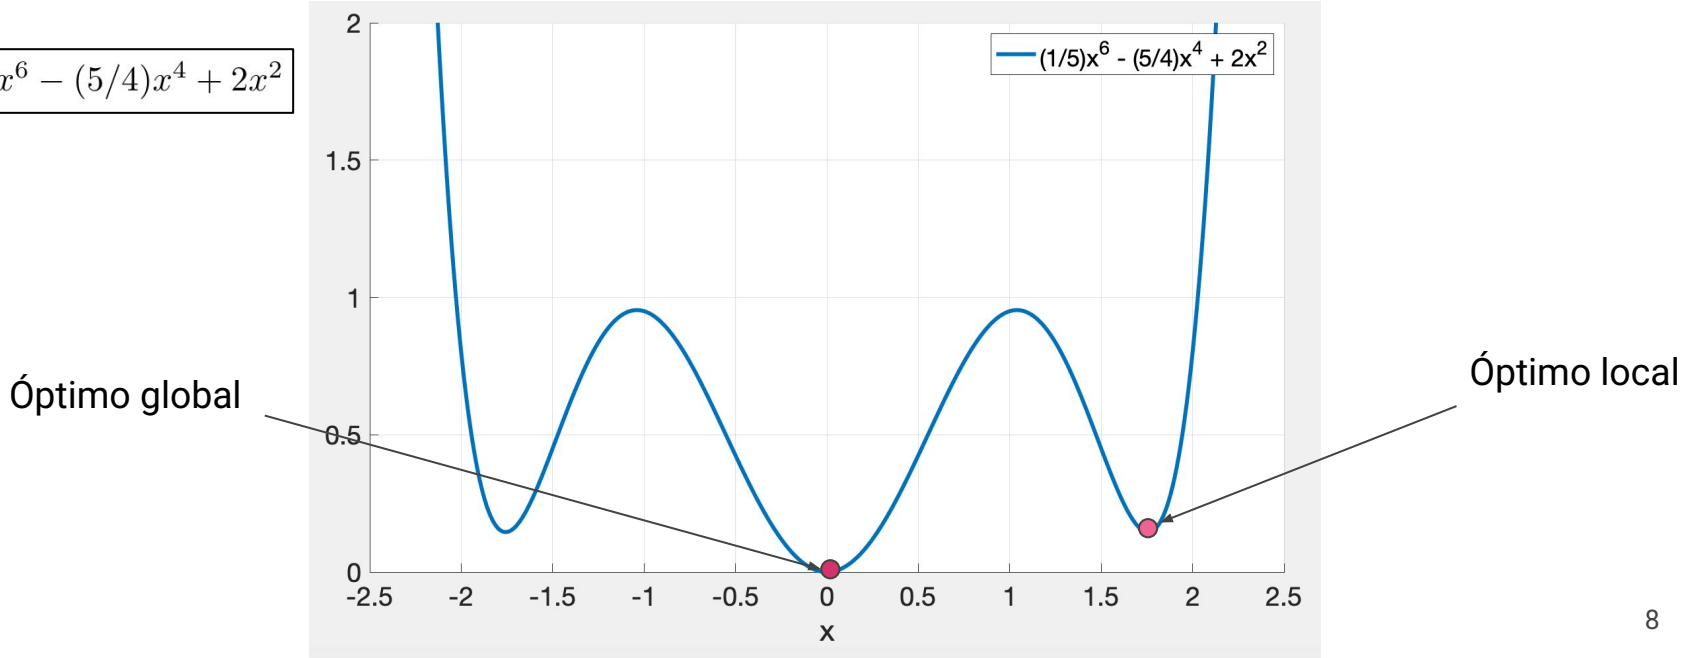

Condiciones de Optimalidad Local

Si f(x) es continua y doblemente diferenciable:

- **Condición de primer orden**
  - $\nabla f(x^*) = 0$

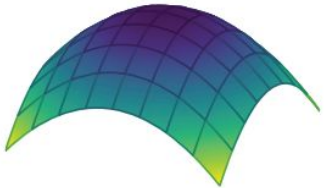

A *local maximum*. The gradient at the center is zero, but the Hessian is negative definite.

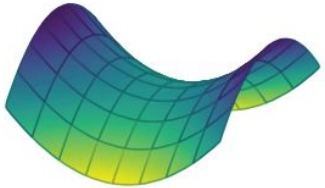

A *saddle*. The gradient at the center is zero, but it is not a local minimum.

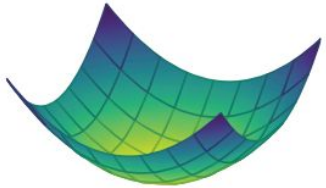

A *bowl*. The gradient at the center is zero and the Hessian is positive definite. It is a local minimum.

- **Condición de segundo orden** (necesaria, suficiente)
  - **Mínimo local**: $\nabla^2 f(x^*) \geq 0$ (semidefinida +, "débil"), $\nabla^2 f(x^*) > 0$ (definida +, "fuerte")
  - **Máximo local**: $\nabla^2 f(x^*) \leq 0$ (semidefinida -, "débil"), $\nabla^2 f(x^*) < 0$ (definida -, "fuerte")

Visualización de Problemas de Optimización

- Es importante poder visualizar la geometría de un problema de optimización
  - La forma de la superficie de la función objetivo
  - La forma del conjunto factible, definido por las restricciones
  - Para esto debemos conocer la geometría de las distintas funciones básicas (lineales, cuadráticas, exponenciales, etc.), y las geometría inducidas por las restricciones
- Visualizar nos ayuda a:
  - Elegir el algoritmo de optimización
  - Definir puntos semilla o hiperparámetros del algoritmo
  - Entender por qué un algoritmo no está funcionando como lo esperamos (no encuentra una solución, da mensajes de error, etc.)
- Para problemas pequeños, se puede graficar manual o computacionalmente
- Para problemas mas grandes, debemos desarrollar la capacidad para visualizarlo mentalmente

Visualización de Problemas de Optimización

The function $f(x_1, x_2) = x_1^2 - x_2^2$. This function can be visualized in a three-dimensional space based on its two inputs and one output. It can also be visualized using a contour plot, which shows lines of constant y value. A three-dimensional visualization and a contour plot are shown below.

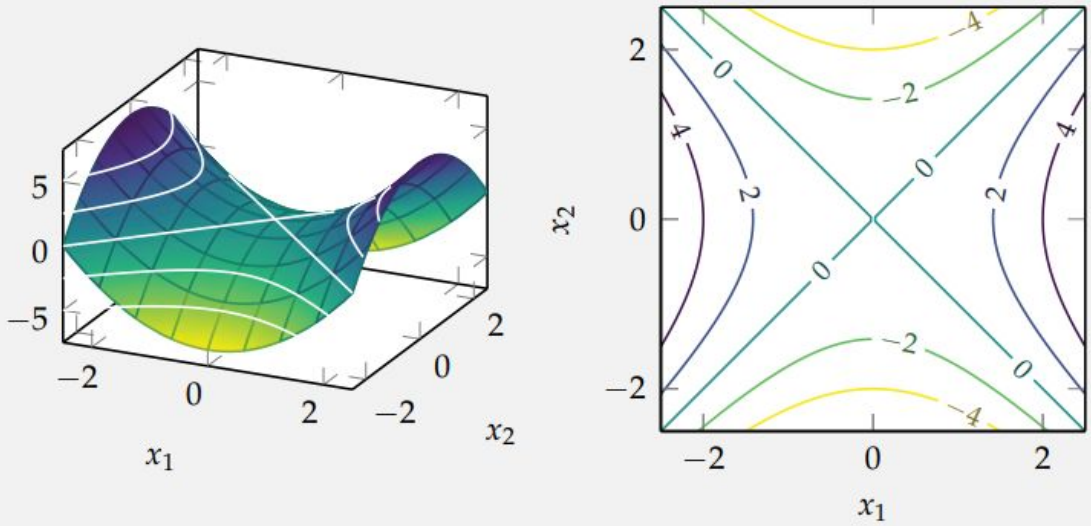

max/min vs. argmax/argmin

- Operador “max/min” devuelve el **valor óptimo**

  10000 = **max** x*(200 - x)

- Operador “argmax/argmin” devuelve el **punto óptimo**

  100 = **argmax** x*(200 - x)

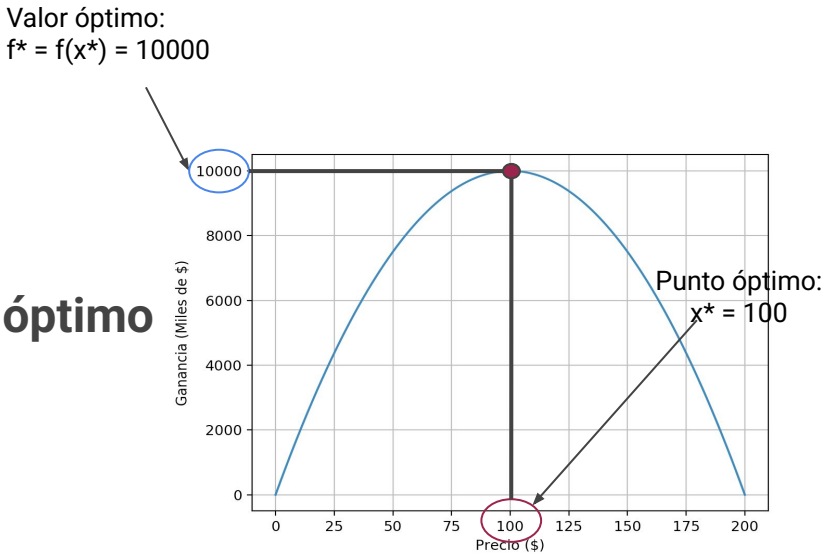

Nota: en la práctica muchas veces usamos max/min para denotar el problema de optimización

Equivalencias entre problemas de optimización

1. **max f(x) = min - f(x)**

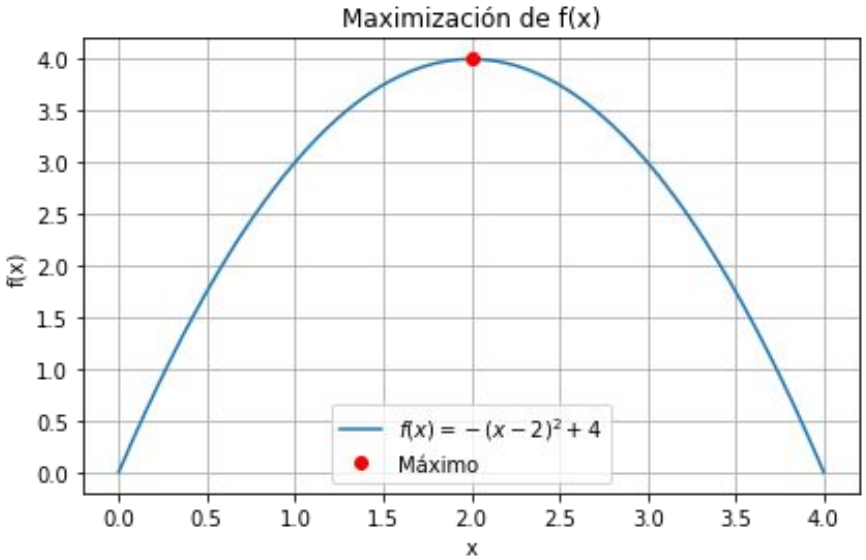

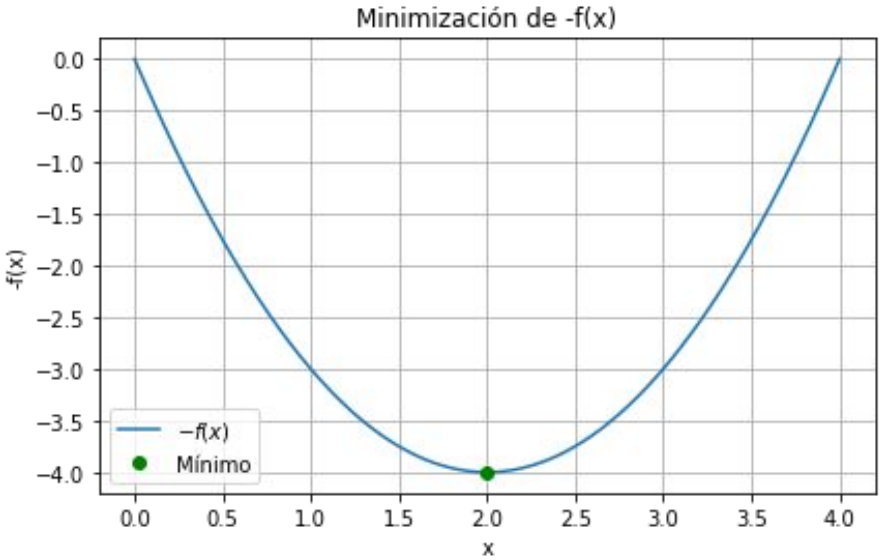

$$\underset{\mathbf{x}}{\text{maximize}}\ f(\mathbf{x}) \text{ subject to } \mathbf{x} \in \mathcal{X}$$

$$\underset{\mathbf{x}}{\text{minimize}}\ -f(\mathbf{x}) \text{ subject to } \mathbf{x} \in \mathcal{X}$$

Equivalencias entre problemas de optimización

2. **min f(x) = min g(f(x))** , si g(z) es monotónicamente creciente

No cambia el signo de la curvatura

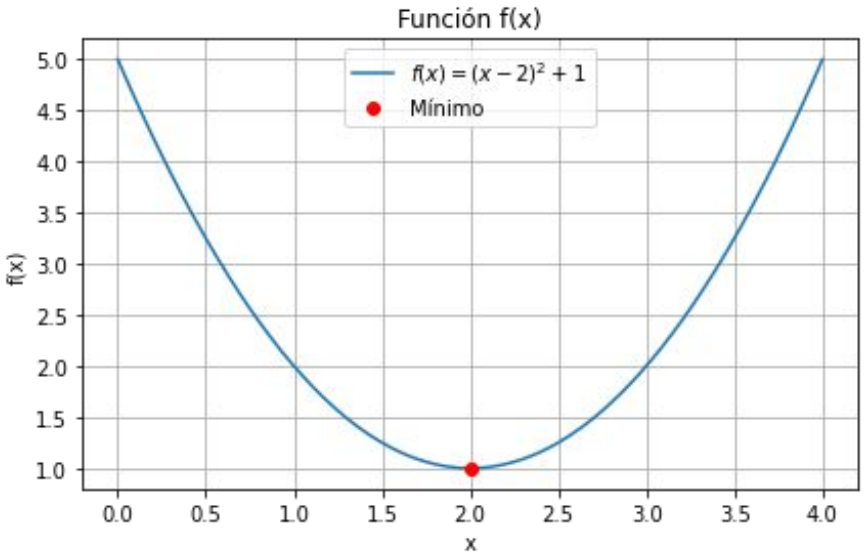

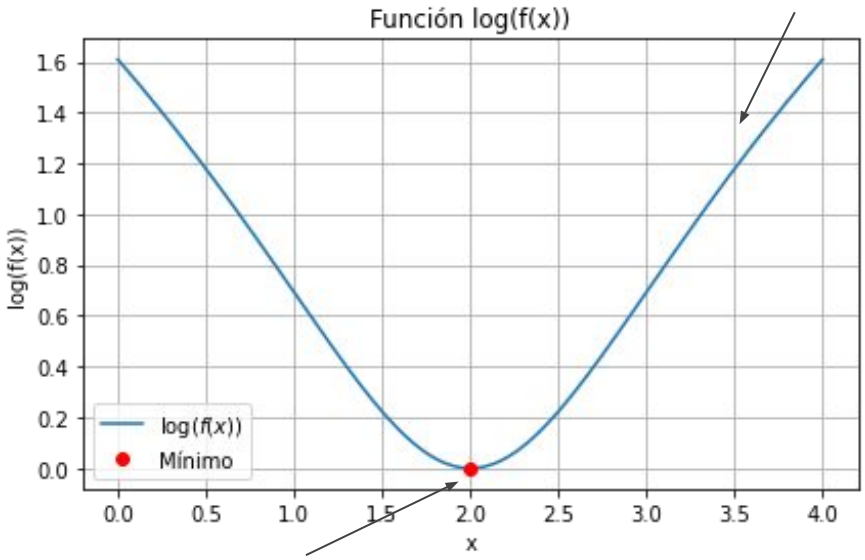

No cambian los puntos críticos

Optimización Multi-Objetivo

- Supongamos que tenemos dos funciones objetivo, $f(x)$ y $g(x)$ que se quieren minimizar en simultáneo
- A menos que ambos tengan el mínimo en el mismo lugar, será imposible minimizar ambos al mismo tiempo $\rightarrow$ trade-off
- Idea: minimizar $h(x) = f(x) + \lambda g(x)$ donde λ regula la importancia/peso que le doy a cada función
  - $\lambda = 0 \quad \rightarrow \quad \min f(x)$
  - $\lambda \rightarrow \infty \quad \rightarrow \quad \min g(x)$
- λ define la importancia relativa de cada función a minimizar

Optimización Multi-Objetivo

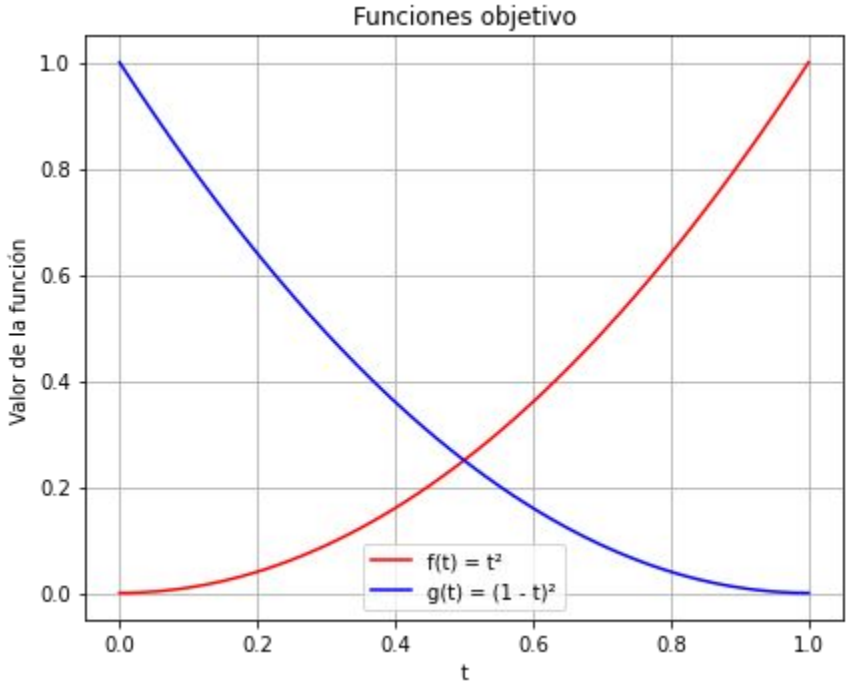

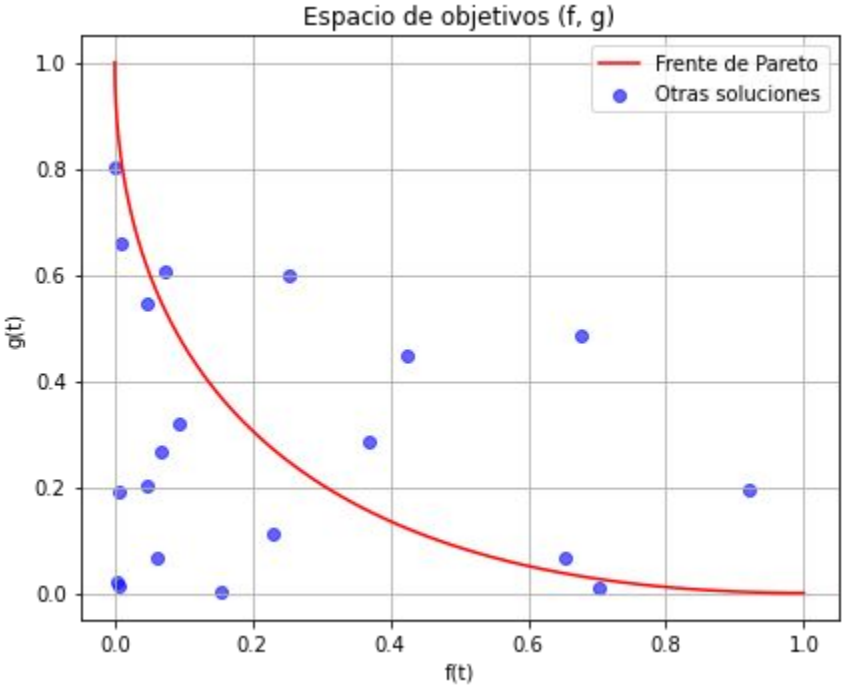

¿Cómo encontrar un óptimo?

¿Cómo podemos encontrar un óptimo?

1. **Analíticamente**: Resolviendo las condiciones de optimalidad
2. **Numéricamente**: No resolvemos las ecuaciones de manera explícita, sino que empleamos algoritmos iterativos para aproximar la solución
    - Función muy compleja para resolver analíticamente
    - Número de variables muy grande

Métodos Numéricos para Optimización

Métodos de Primer Orden vs. Segundo Orden

- Métodos de primer orden:
  - Utilizan información relacionada al gradiente de la función objetivo y restricciones
  - Suelen ser computacionalmente menos intensivos y escalar mejor con la cantidad de variables
  - Su velocidad de convergencia (por iteración) suele ser menor
- Métodos de segundo orden:
  - Utilizan información relacionada al gradiente y hessiano de la función objetivo y restricciones
  - Suelen ser computacionalmente más intensivos y escalar peor con la cantidad de variables
  - Su velocidad de convergencia (por iteración) suele ser mayor que los algoritmos de primer orden

NOTA: estos conceptos son generalización, que pueden ser más (o menos) correctas, dependiendo del algoritmo de optimización en cuestión y del problema de optimización a abordar

Método de Primer Orden

Ejemplo: Método Descenso por Gradiente

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

α_k : learning rate

$$\min \quad x^2$$

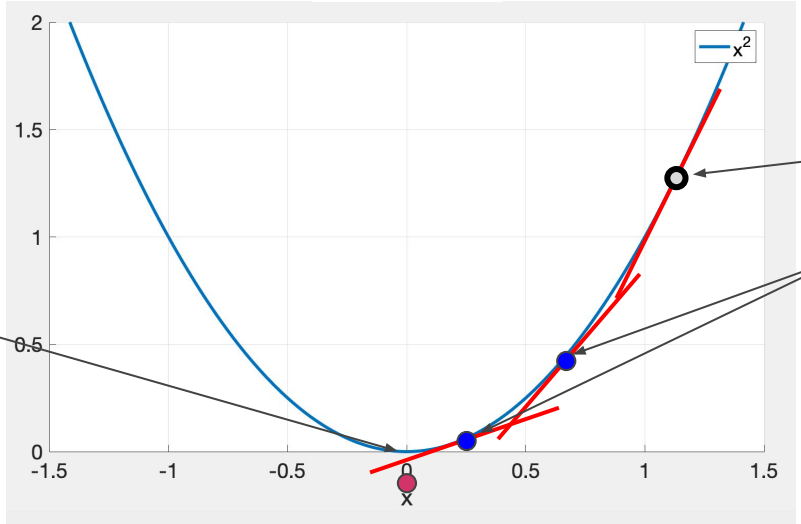

Punto semilla (x0)

Iteraciones

Punto óptimo x*

Método de Segundo Orden

Ejemplo: Método de Newton

$$x_{k+1} = x_k - (\nabla^2 f(x_k))^{-1} . \nabla f(x_k)$$

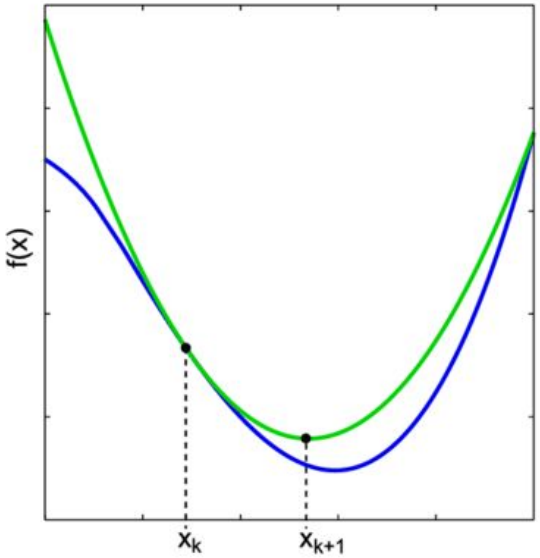

- Requiere computar el gradiente y el Hessiano, y además invertir el Hessiano

Puntos semilla randomizados

- Puedo correr la optimización muchas veces con distintos puntos semilla
- Si siempre llego al mismo punto, entonces uno puede ***sospechar*** de que sea un óptimo global
- Si llego a distintos puntos, tomo el que tiene mejor valor de la función objetivo

Criterios de Convergencia

- Define una condición para dar por terminada la búsqueda
- Existen diversos criterios de convergencia:
  - La variable de diseño no ha cambiado
  - La función objetivo no ha cambiado
  - La norma del gradiente es suficientemente chico
  - …
- Limitar la cantidad de iteraciones:
  - Suele ser una buena idea poner un límite a la cantidad de iteraciones, para evitar la posibilidad de que el algoritmo corra ad-infinitum

Optimización Convexa

Función Convexa

- Si dibujo una línea entre dos puntos de una **función convexa**, los puntos intermedios siempre están **en o encima** de la función

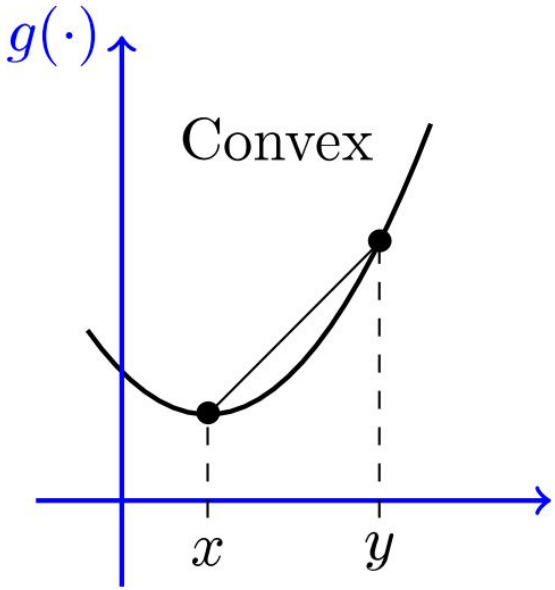

Matemáticamente:

$<$ Estríctamente convexa

$$f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta) f(y)$$

$$0 \leq \theta \leq 1$$

Para funciones doblemente diferenciables:

$$\nabla^2 f(x) \succeq 0 \quad \text{for all } x \in \mathbf{dom}\, f$$

$>$ Estríctamente convexa

Función Convexa

- Si dibujo una línea entre dos puntos de una **función convexa**, los puntos intermedios siempre están **en o encima** de la función

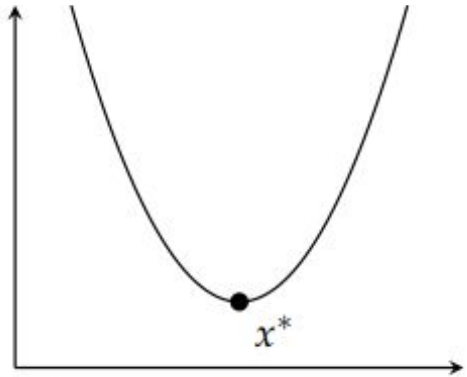

Strictly convex function with one global minimum.

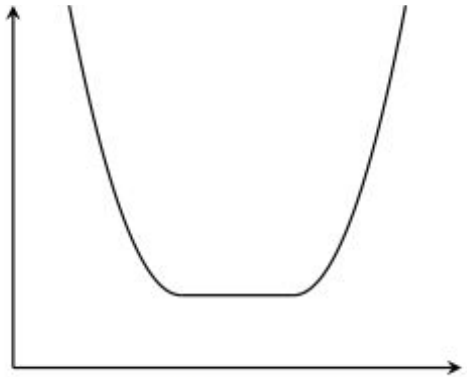

Convex function without a unique global minimum.

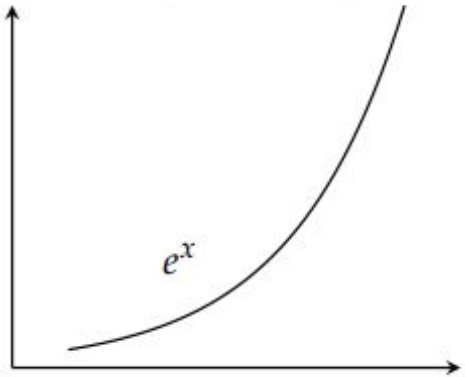

Strictly convex function without a global minimum.

Función Convexa

- No todas las funciones convexas son unimodales y no todas las funciones unimodales son convexas

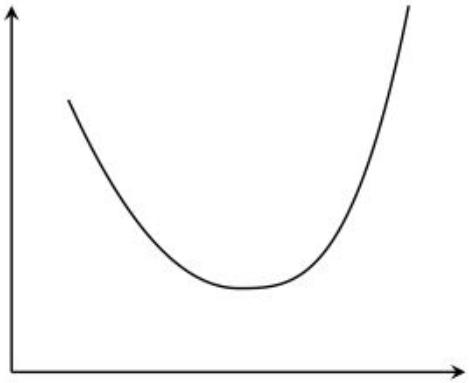

Unimodal and convex

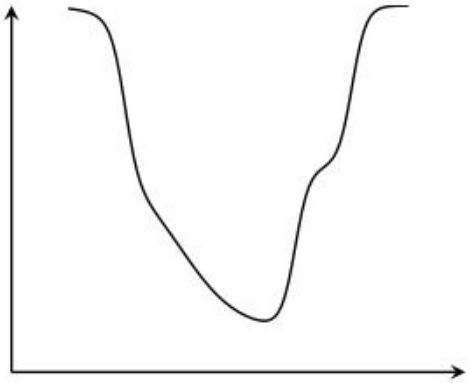

Unimodal but nonconvex

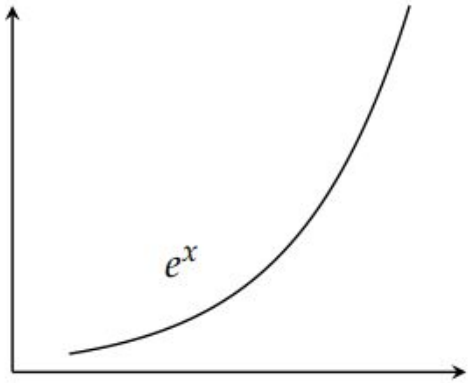

Convex but nonunimodal

Función Cóncava

- Si dibujo una línea entre dos puntos de una **función cóncava**, los puntos intermedios sobre la línea siempre están **en o debajo** de la función
- f(x) es cóncava $\Leftrightarrow$ -f(x) es convexa

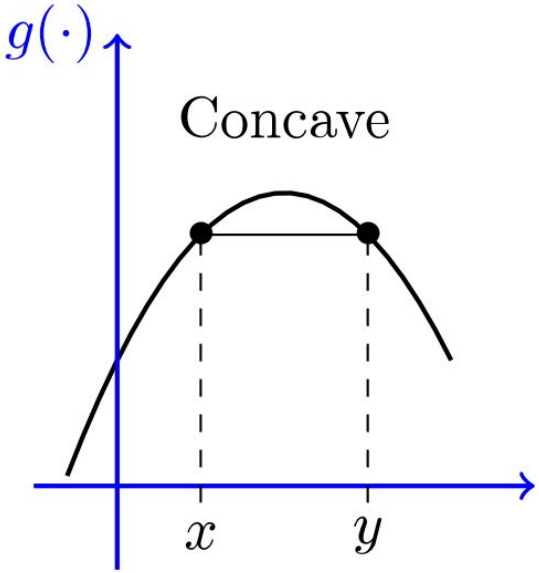

Función Cóncava: Ejemplos

$$f(x) = -x^2$$

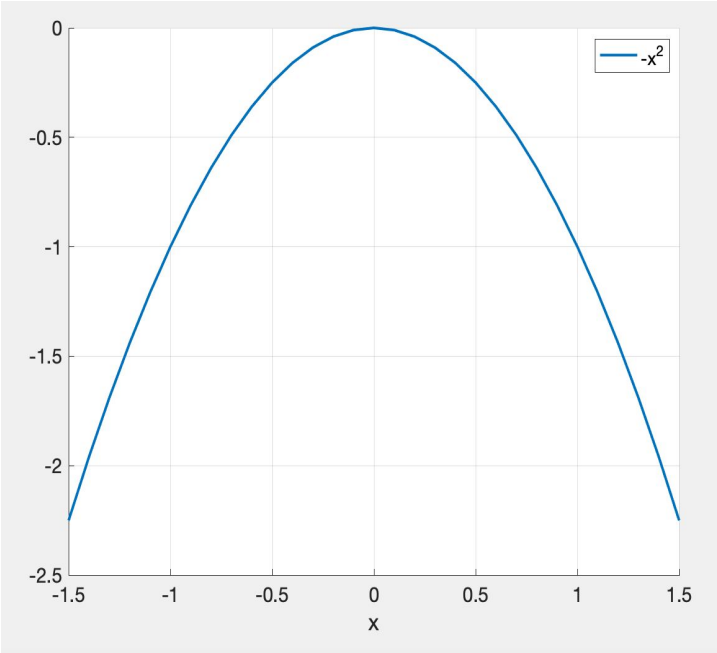

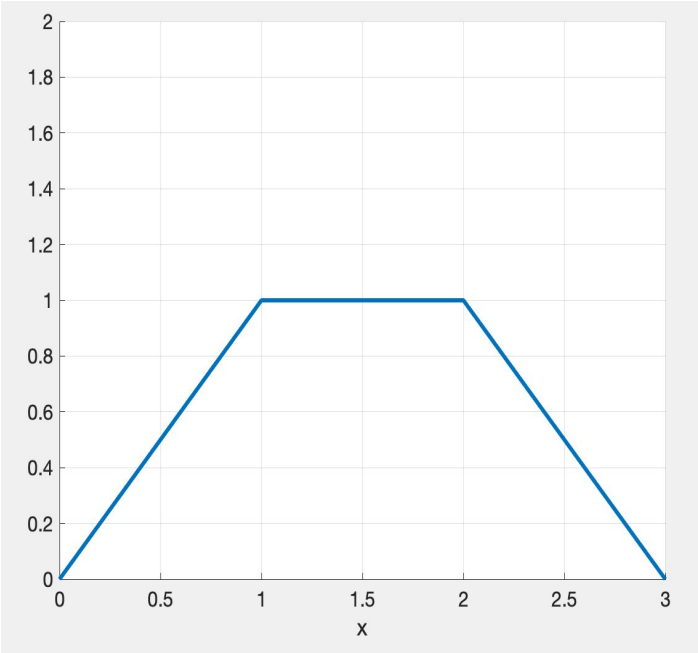

Funciones Lineales: ¿cóncava o convexa?

$$f(x) = x$$

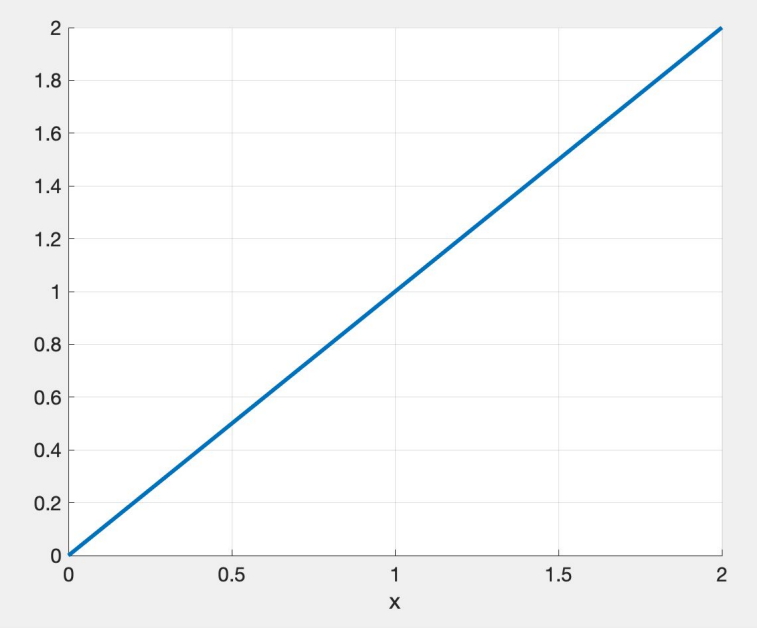

Funciones Lineales

- Las funciones lineales son tanto convexas como cóncavas

$$f(x) = x$$

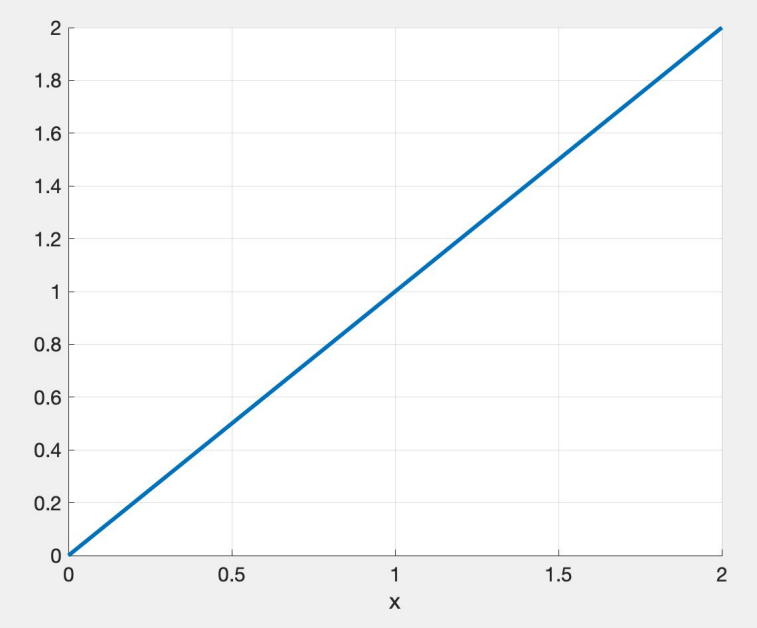

Minimización de una Función Convexa

- No hay chance de caer en un óptimo local, porque hay un solo valle
- **¡Siempre llegamos al óptimo!**

$$\min x^2$$

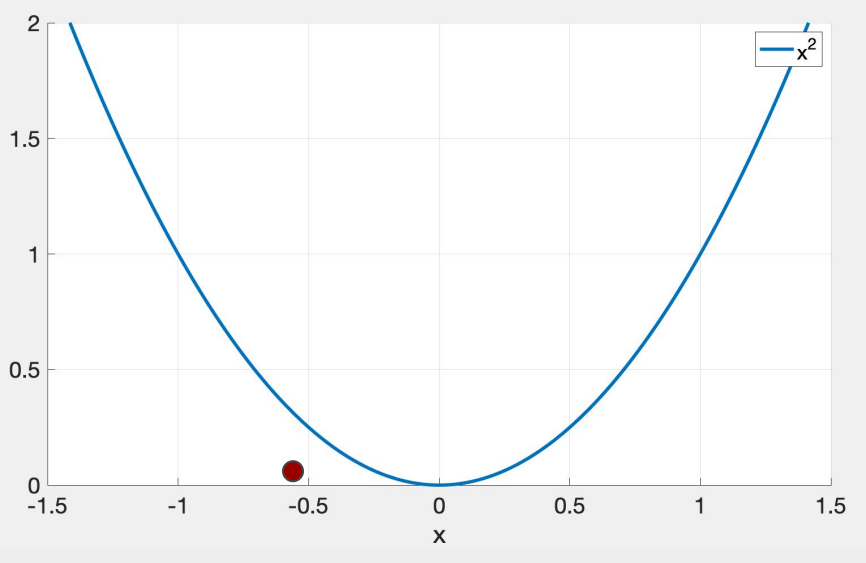

Maximización de una Función Cóncava

- No hay chance de caer un óptimo local, porque hay una solo cresta
- **¡Siempre llegamos al óptimo!**

$$\max x^2$$

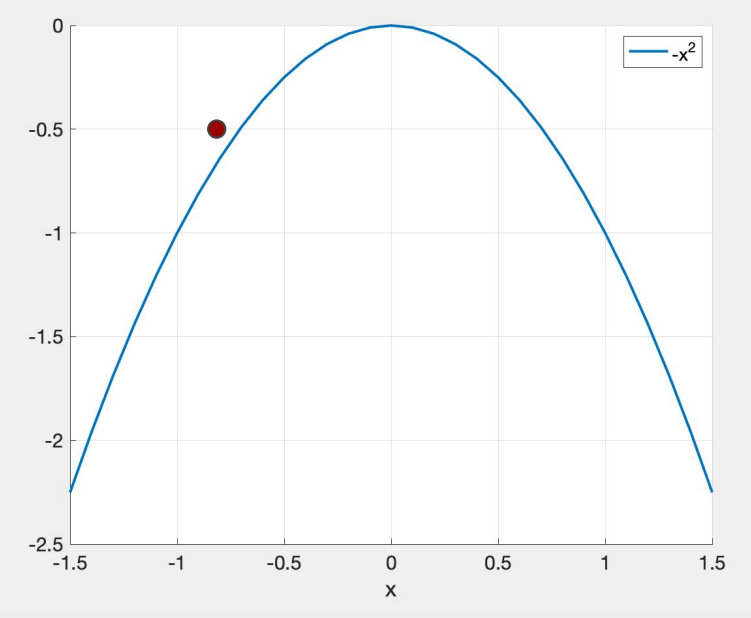

Conjunto Convexo

- Un conjunto es convexo si la línea que une cualquier par de puntos en el conjunto también pertenece al conjunto

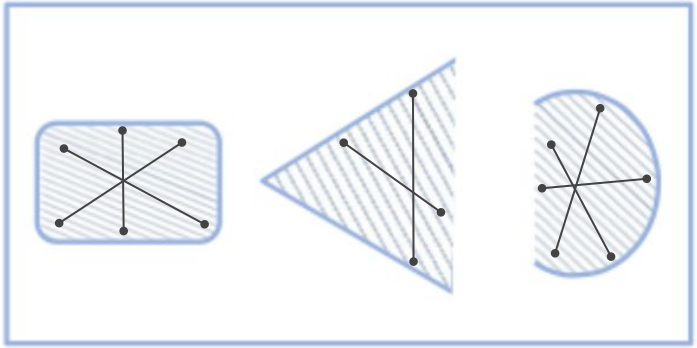

Convex

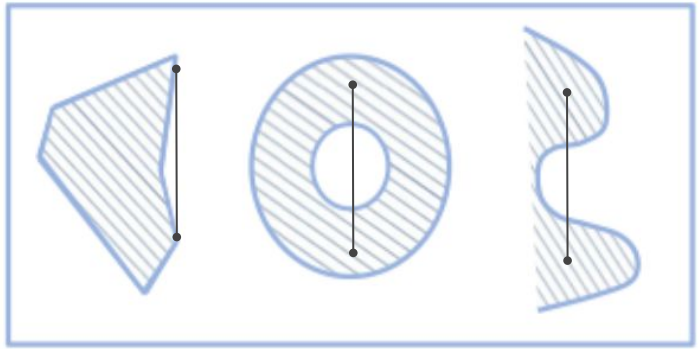

Not Convex

Problema de Optimización Convexa

Problema de optimización es convexo $\Leftrightarrow$

1. Conjunto factible es convexo

   y además:

2. El objetivo es:
   - **Minimizar** una función **convexa**

     ó
   - **Maximizar** una función **cóncava**

Conjunto factible convexo **Y** (min convexa **Ó** max cóncava) $\Leftrightarrow$ Problema de Opt. Convexo

Optimización Convexa

- Si un problema de optimización es convexo:

  ⇒ **cualquier óptimo local** que encontremos **es también un óptimo global**

  ⇒ si encontramos un óptimo local podemos garantizar que es óptimo global!

- Los problemas de optimización convexos son **“fáciles” de resolver**
- Hay métodos numéricos para optimización convexa que son muy rápidos y escalables

Determinar Convexitud

Funciones Convexas

- **Lineal:** $f(x) = ax + b$
- **Exponencial:** $f(x) = e^{\alpha x} \quad \forall \alpha \in \mathbf{R}$

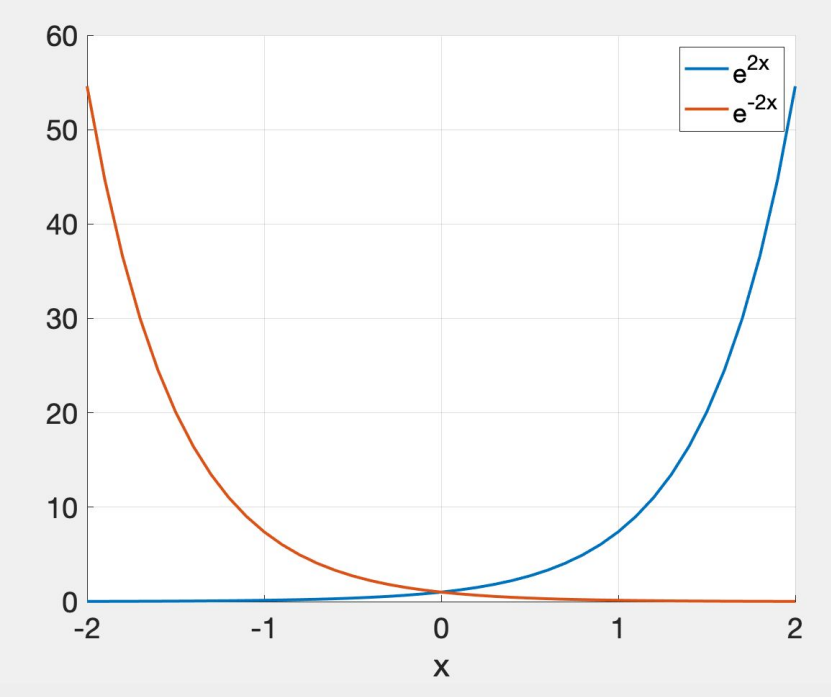

Funciones Convexas

- **Potencias:** $$f(x) = x^{\alpha}$$
$$x \geq 0$$
$$\alpha \geq 1 \;\; ó \;\; \alpha \leq 0$$

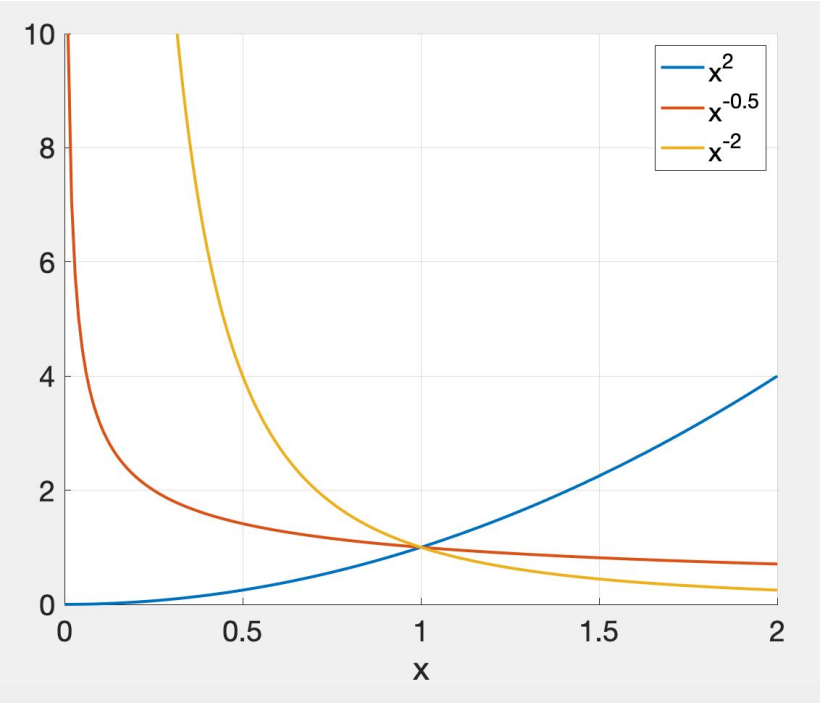

Funciones Convexas

- **Potencias del valor absoluto:**

$$f(x) = |x|^p$$
$$p \geq 1$$

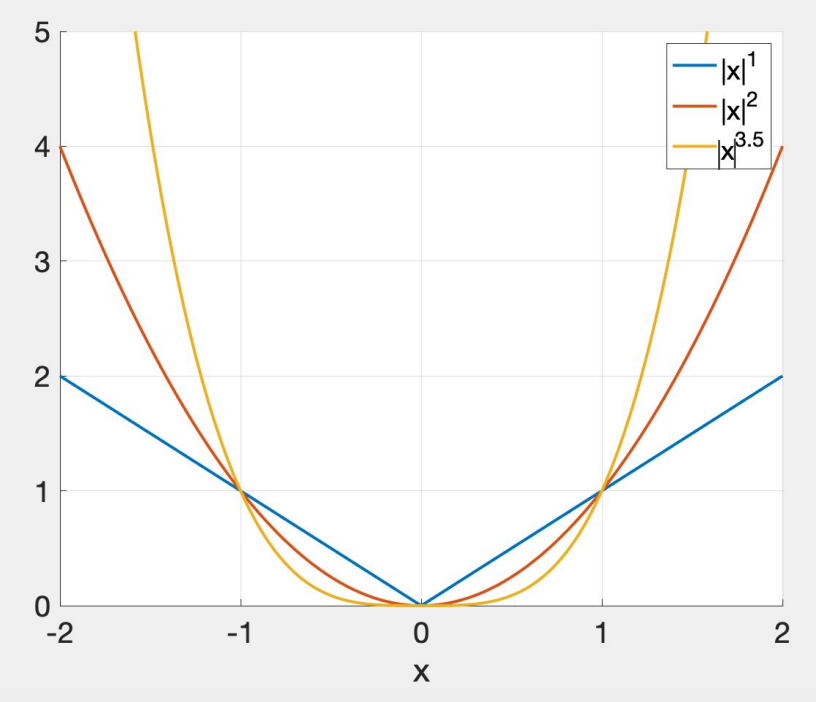

Funciones Convexas

- **Cuadrática:**
  - Depende de los valores de los coeficientes
  - Por ejemplo: $f(x) = x_1^2 + x_2^2 + \alpha x_1 x_2 = x^T \begin{bmatrix} 1 & \sqrt{\alpha} \\ \sqrt{\alpha} & 1 \end{bmatrix} x$

Matriz semidefinida positiva

$$0 \leq \alpha \leq 2$$

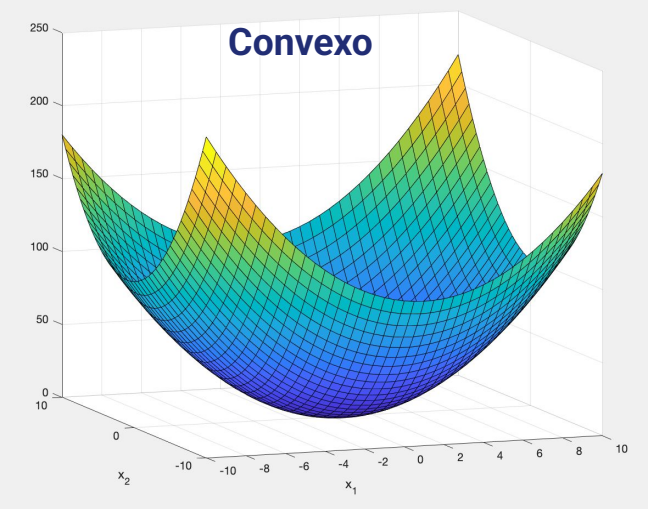

$$2 < \alpha$$

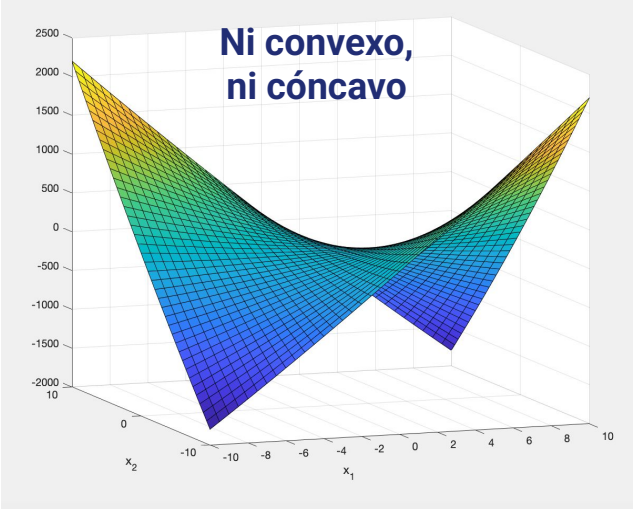

Funciones Cóncavas

- **Lineal:** $f(x) = ax + b$
- **Potencias:** $f(x) = x^{\alpha}$

$$x \geq 0$$
$$0 \leq \alpha \leq 1$$

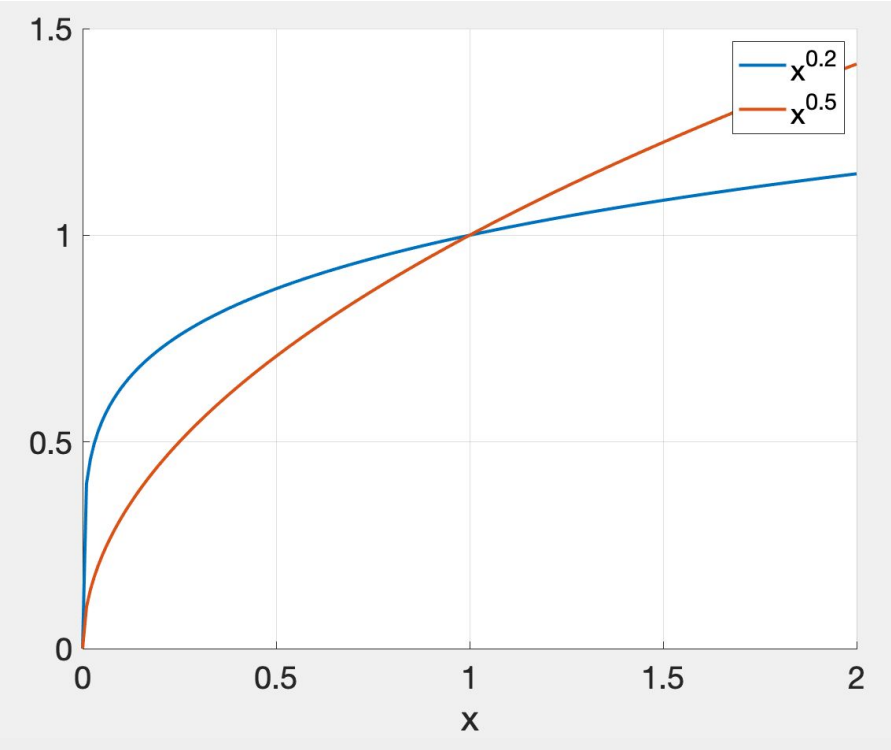

Funciones Cóncavas

- **Logaritmo:** $f(x) = log(x)$
  $x > 0$

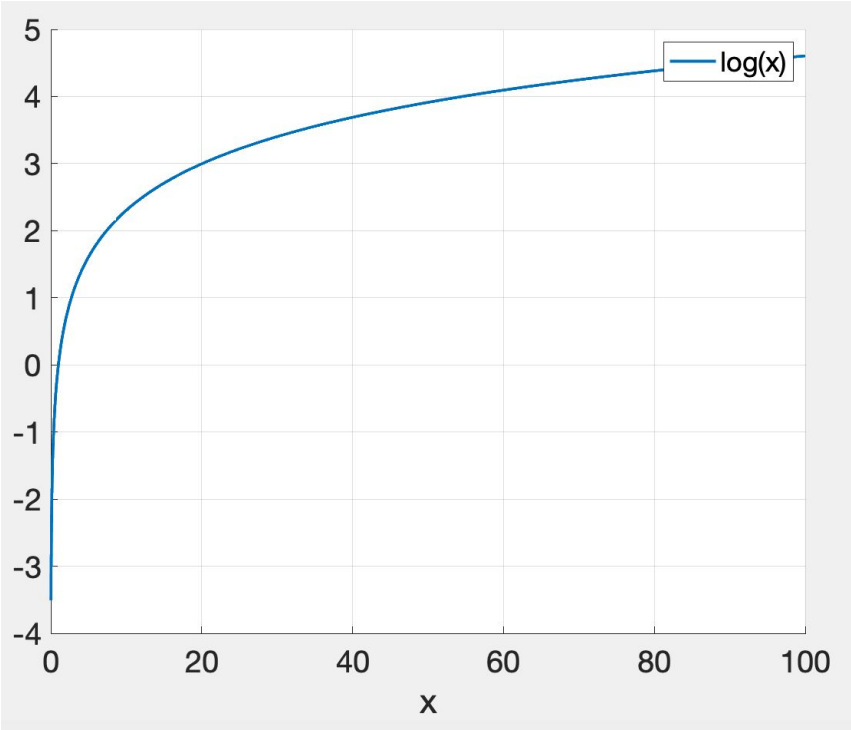

Funciones Cóncavas

- **Entropía:** $f(x) = -xlog(x)$
  $x > 0$

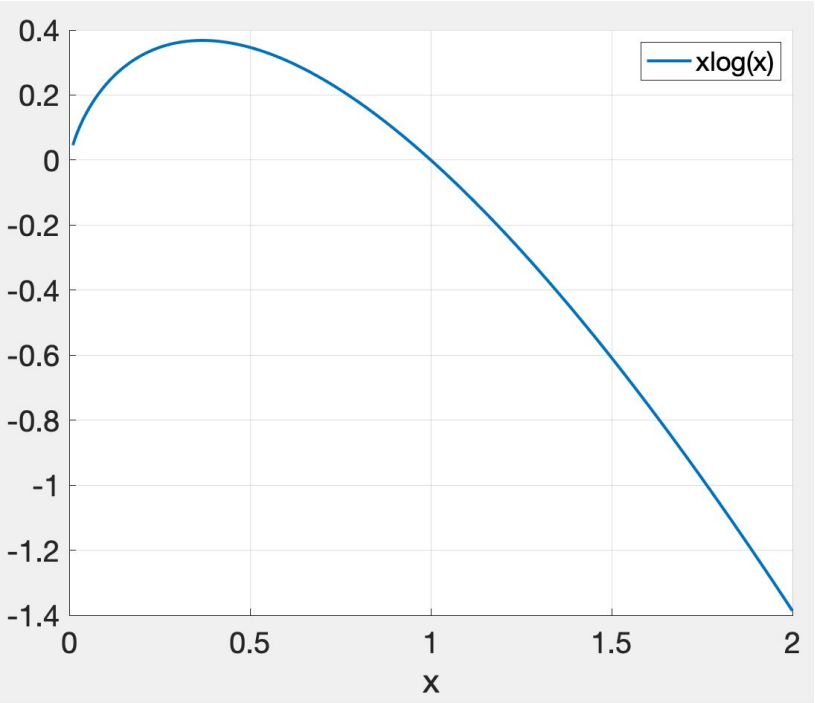

Funciones Cóncavas

- **Cuadrática:**
  - Depende de los valores de los coeficientes
  - Por ejemplo: $f(x) = -x_1^2 - x_2^2 - \alpha x_1 x_2 = x^T \begin{bmatrix} -1 & \sqrt{\alpha} \\ \sqrt{\alpha} & -1 \end{bmatrix} x$

$0 \leq \alpha \leq 2$

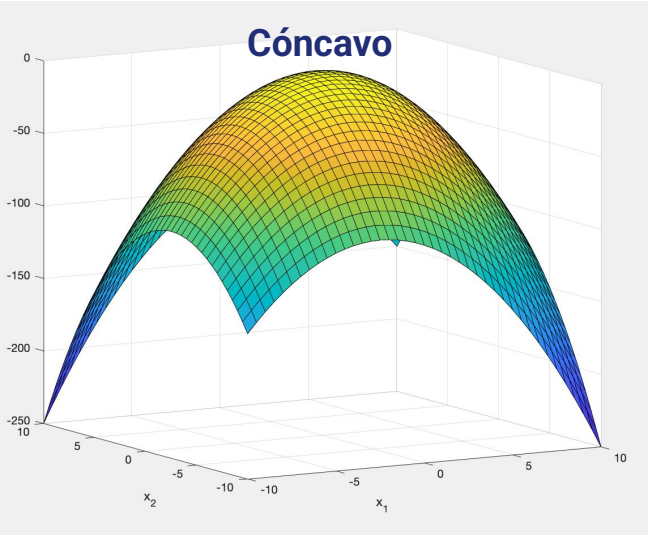

$2 < \alpha$

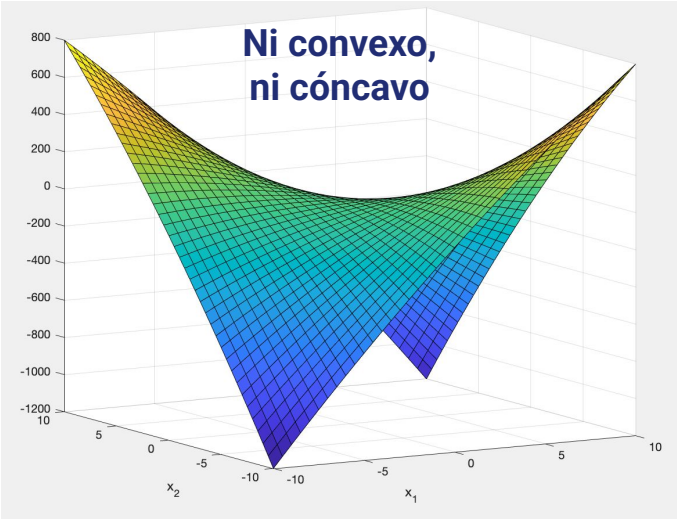

Funciones Convexas/Cóncavas (Por Construcción)

- Suma de funciones convexas/cóncavas:
  - Convexa + Convexa = Convexa
  - Cóncava + Cóncava = Cóncava
  - Convexa + Cóncava = ??
- Mínimo/Máximo:
  - El máximo de funciones convexas es convexa
  - El mínimo de funciones cóncavas es cóncava
- Composición de funciones:

composition of $g : \mathbf{R}^n \to \mathbf{R}$ and $h : \mathbf{R} \to \mathbf{R}$:

$$f(x) = h(g(x))$$

f is convex if
- g convex, h convex, $\tilde{h}$ nondecreasing
- g concave, h convex, $\tilde{h}$ nonincreasing

Construcción de Funciones Convexas/Cóncavas

- Suma de funciones convexas/cóncavas:
  - Convexa + Convexa = Convexa
  - Cóncava + Cóncava = Cóncava
  - Convexa + Cóncava = ??
- Mínimo/Máximo:
  - El máximo de funciones convexas es convexa
  - El mínimo de funciones cóncavas es cóncava
- Composición de funciones:

composition of $g : \mathbf{R}^n \to \mathbf{R}$ and $h : \mathbf{R} \to \mathbf{R}$:

$$f(x) = h(g(x))$$

f is convex if $\begin{array}{l} g \text{ convex, } h \text{ convex, } \tilde{h} \text{ nondecreasing} \\ g \text{ concave, } h \text{ convex, } \tilde{h} \text{ nonincreasing} \end{array}$

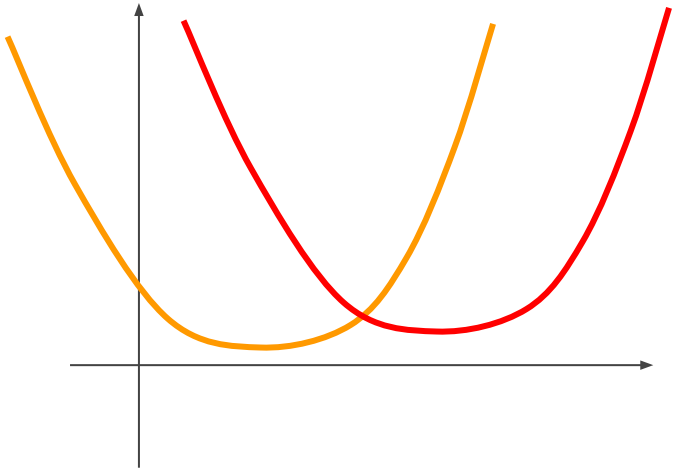

Construcción de Funciones Convexas/Cóncavas

- Suma de funciones convexas/cóncavas:
  - Convexa + Convexa = Convexa
  - Cóncava + Cóncava = Cóncava
  - Convexa + Cóncava = ??
- Mínimo/Máximo:
  - El máximo de funciones convexas es convexa
  - El mínimo de funciones cóncavas es cóncava
- Composición de funciones:

composition of $g : \mathbf{R}^n \to \mathbf{R}$ and $h : \mathbf{R} \to \mathbf{R}$:

$$f(x) = h(g(x))$$

f is convex if $\begin{array}{l} g \text{ convex, } h \text{ convex, } \tilde{h} \text{ nondecreasing} \\ g \text{ concave, } h \text{ convex, } \tilde{h} \text{ nonincreasing} \end{array}$

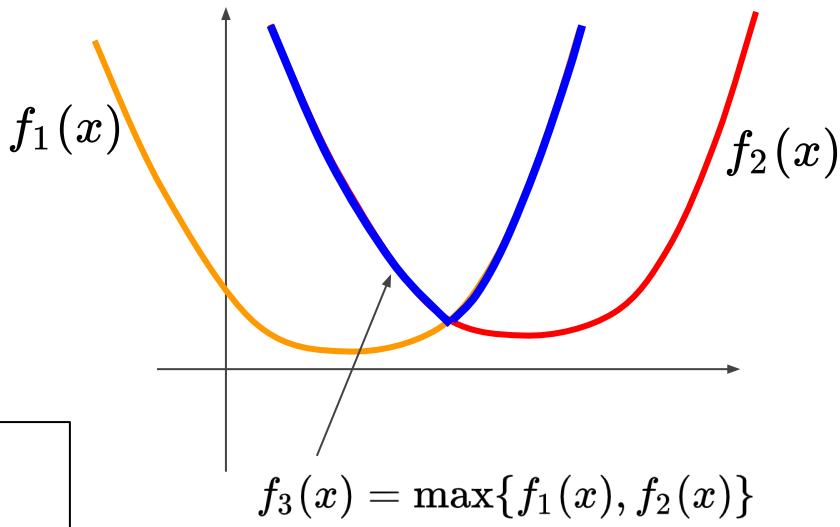

Construcción de Funciones Convexas/Cóncavas

- Suma de funciones convexas/cóncavas:
  - Convexa + Convexa = Convexa
  - Cóncava + Cóncava = Cóncava
  - Convexa + Cóncava = ??
- Mínimo/Máximo:
  - El máximo de funciones convexas es convexa
  - El mínimo de funciones cóncavas es cóncava
- Composición de funciones:

composition of $g : \mathbf{R}^n \to \mathbf{R}$ and $h : \mathbf{R} \to \mathbf{R}$:

$$f(x) = h(g(x))$$

f is convex if $\begin{array}{l} g \text{ convex, } h \text{ convex, } \tilde{h} \text{ nondecreasing} \\ g \text{ concave, } h \text{ convex, } \tilde{h} \text{ nonincreasing} \end{array}$

$$g(x) = x^2$$
$$h(y) = e^y$$
$$f(x) = h(g(x)) = e^{x^2}$$

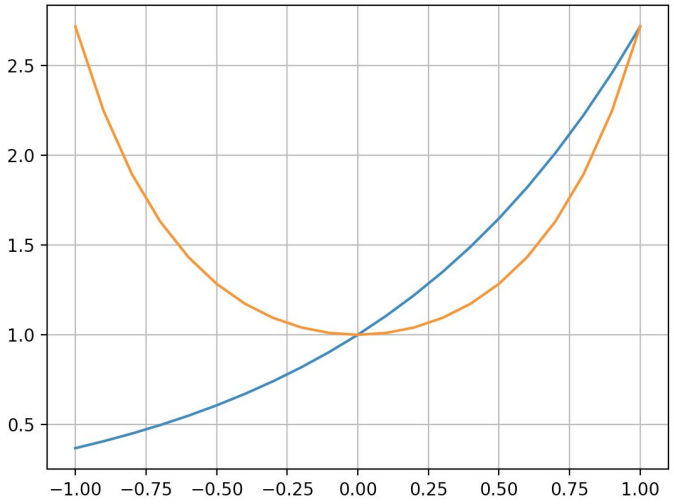

Conjuntos Convexos

- Igualdad lineal: $Ax = b$
- Desigualdad lineal: $Ax \geq b$
- Desigualdad circular: $||x - x_c||^2 \leq r^2$
- Desigualdad elíptica: $||A(x - x_c)||^2 \leq 1$
- Desigualdad parabólica: $x_1^2 \leq x_2$
- Desigualdad cónica: $|x_1| \leq x_2$

Multiplicidad e inexistencia de óptimo

Múltiples Óptimos

- ¿Es posible que haya más de un óptimo?
- ¿Si quiero maximizar, cuál es/son el/los punto(s) óptimos?

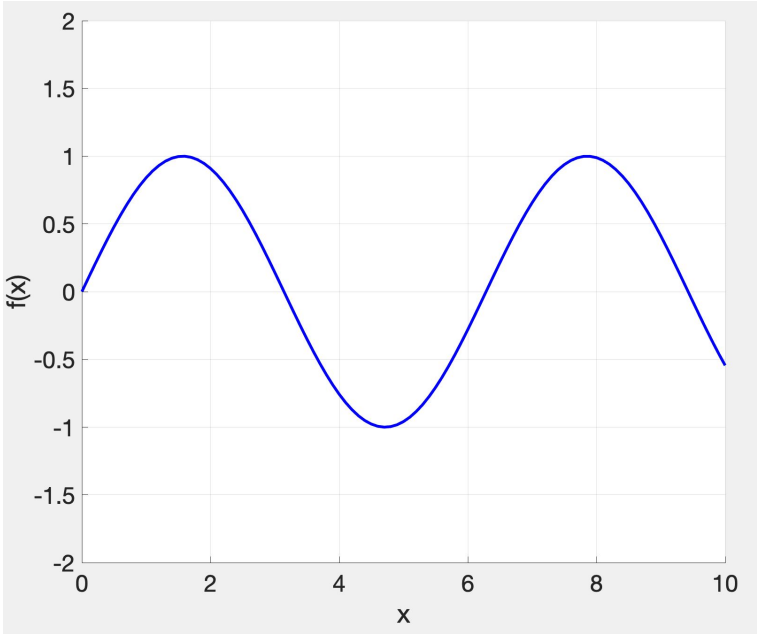

Múltiples Óptimos

- ¿Es posible que haya más de un óptimo?
- ¿Si quiero maximizar, cuál es/son el/los punto(s) óptimos?

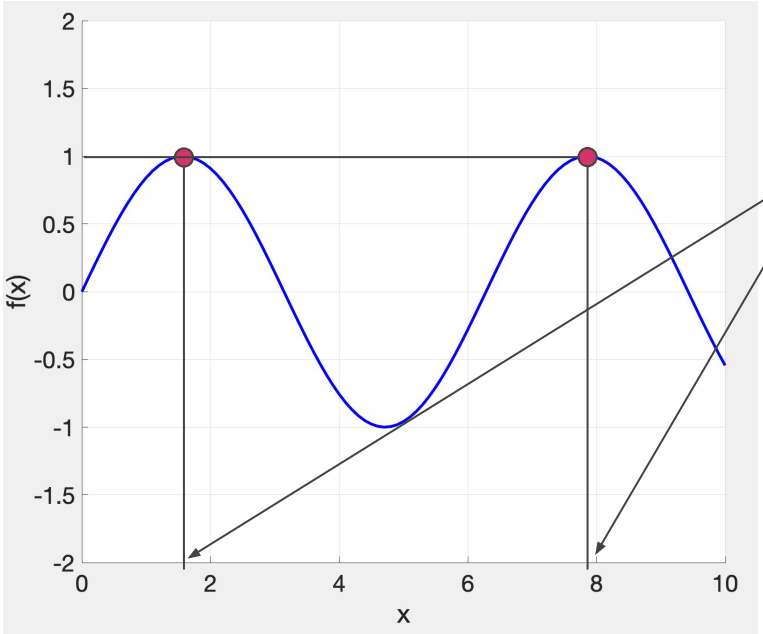

Dos puntos óptimos!

Múltiples Óptimos

- ¿Es posible que haya más de un óptimo?
- ¿Si quiero maximizar, cuál es/son el/los punto(s) óptimos?

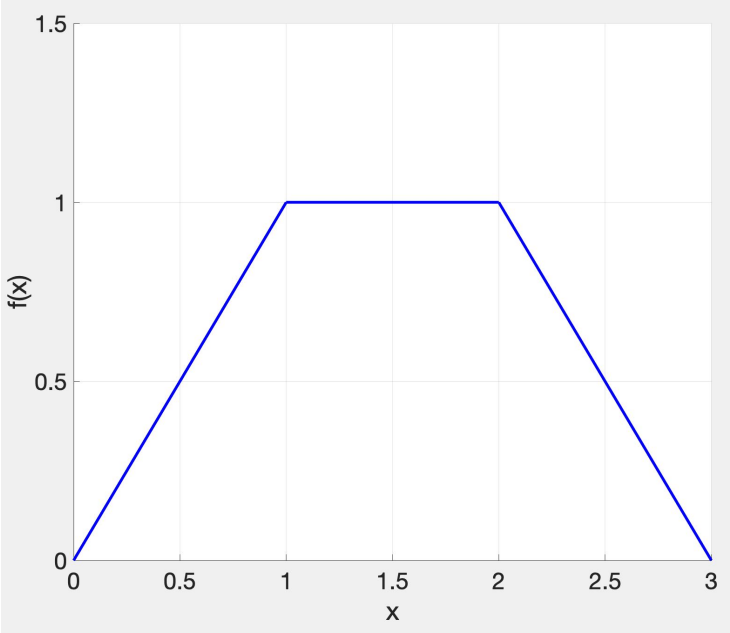

Múltiples Óptimos

- ¿Es posible que haya más de un óptimo?
- ¿Si quiero maximizar, cuál es/son el/los punto(s) óptimos?

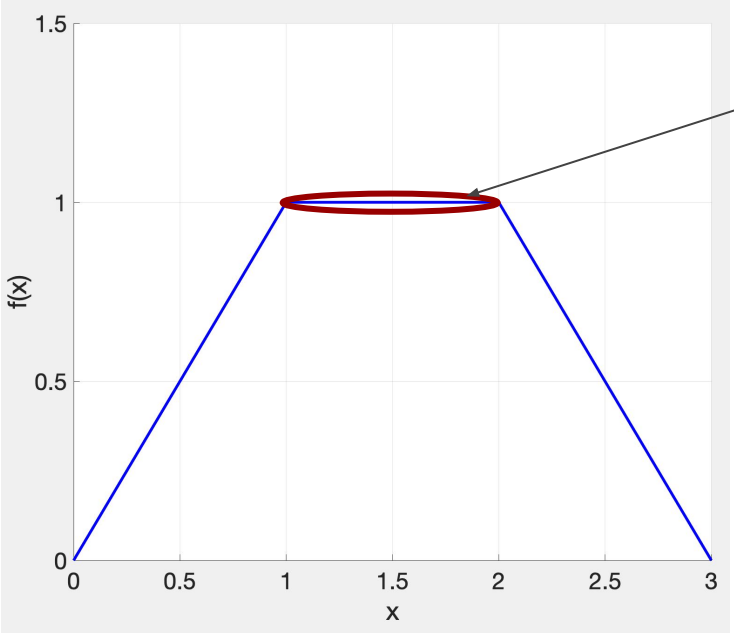

Todos los puntos entre 1 y 2 son óptimos!

Inexistencia de Óptimo: Caso 1

<u>Caso 1</u>: El **conjunto factible es nulo** (o sea no existe ningún punto que satisface las restricciones)

Ejemplo:

$$\max_{x} \quad x$$

$$\left.\begin{aligned} x &\leq 0 \\ 2 &\leq x \end{aligned}\right\}$$

No existe x que cumpla con estas condiciones simultáneamente!

Inexistencia de Óptimo: Caso 2

<u>Caso 2:</u> Función objetivo no acotada

- El conjunto factible y la función objetivo son tales que siempre puedo encontrar un x con mejor performance, hasta el infinito.

Ejemplo:

$$\max_{x} \quad x$$

$$0 \leq x$$

Puedo ir a la derecha cuanto quiera, y f(x) sigue creciendo

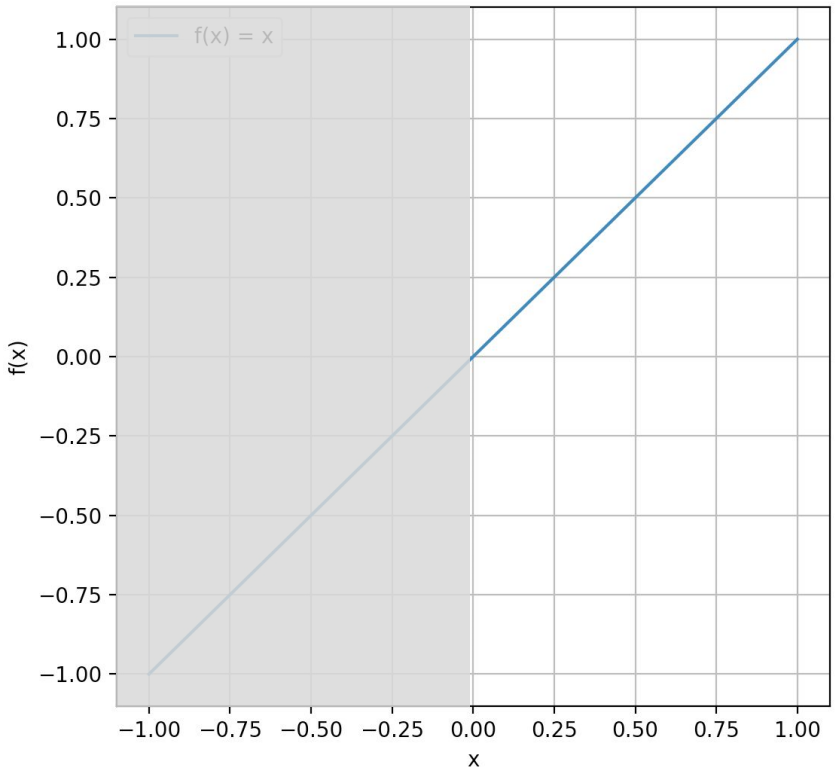

Bibliografía

- Murphy, K. P. (2022). Probabilistic Machine Learning. Massachusetts Institute of Technology. (Capítulo 1.8).
- Kochenderfer, M. J., & Wheeler, T. A. (2019). Algorithms for Optimization. MIT Press. (Capítulos 1, 10 y 12.)